ISSN 2383-630X(Print) / ISSN 2383-6296(Online)
Journal of KIISE, Vol. 53, No. 9, pp. 824-831, 2026. 9
https://doi.org/10.5626/JOK.2026.53.9.824

RAG에서 검색된 문서의 편향성이 생성된 답변에 미치는 영향: 정치적 편향성 실험을 통한 분석

(The Impact of Retrieved Document Bias on Generated Responses in RAG: An Analysis through Political Bias Experiments)

조 승 호 † (Seungho Cho) 고 창 건 †† (Changgeon Ko) 황 태 호 †† (Taeho Hwang) 서 정 연 †† (Jeongyeon Seo) 박 종 철 ††† (Jong C. Park)

요 약 본 연구는 RAG 기반 대규모 언어 모델(LLM)에서 검색된 문서의 편향성이 생성된 답변에 전이되는 현상을 분석해, 검색 문서의 편향성이 생성된 답변에 미치는 영향을 실험적으로 검증했다. 실험 결과, 문서의 편향성이 생성된 답변에 반영됨을 확인했으며, 편향성이 완화된 문서를 참조할 때 생성된 응답의 편향성도 감소하는 것을 관찰하였다. 또한 본 연구에서는 모델에 내재된 편향성과 모델이 참조한 문서의 편향성이 동시에 작용할 때 편향 전이의 강도가 변화하는지 추가적으로 분석했다. 구체적으로, 편향된 LLM이 상반되는 편향성을 가지는 문서를 참조할 경우 상반되는 편향성이 더 강하게 작용했으며, 같은 편향성을 가진 문서를 참조할 경우 응답 변화는 미미했다. 이는 RAG에서 문서 편향성도 중요한 고려 요소임을 보이며, 편향성 연구에서 각 요소의 상호작용을 고려한 종합적인 접근의 중요성을 제시한다.

키워드: 검색 증강 생성, 대규모 언어모델, 인공지능 윤리, 검색된 문서의 편향

Abstract This study investigates the transfer of political bias from retrieved documents to responses generated by Retrieval-Augmented Generation (RAG)-based Large Language Models (LLMs). While prior research has primarily focused on biases within retrievers or LLMs themselves, the impact of document bias has remained largely unexplored. To address this gap, we empirically assessed how political biases from documents-categorized as Left, Center, or Right-influence generated responses. Our results confirm significant bias transfer: politically biased documents noticeably influenced the responses. Specifically, when a right-leaning LLM referenced left-biased documents, its responses shifted toward left bias. Conversely, referencing additional right-leaning documents had only a minimal effect on responses, suggesting the presence of pre-existing internal biases within the LLM. These findings underscore that document biases significantly shape RAG outputs. This highlights the necessity of comprehensive strategies that account for the complex interactions among retrievers, model biases, and document biases to effectively mitigate overall system bias. Such an approach is crucial for developing balanced and reliable RAG-based systems.

Keywords: RAG, LLM, AI ethics, retrieved document bias

· 이 논문은 2024 한국소프트웨어종합학술대회에서 'RAG에서 검색된 문서의 편향성이 생성된 답변에 미치는 영향: 정치적 편향성 실험을 통한 분석'의 제목으로 발표된 논문을 확장한 것임.

† 비 회 원 : 한국과학기술원 전기및전자공학부 학생
cho.seungho@kaist.ac.kr
†† 비 회 원 : 한국과학기술원 전산학부 학생
pencaty@kaist.ac.kr
doubleyyh@kaist.ac.kr
yena.seo@kaist.ac.kr
††† 종신회원 : 한국과학기술원 전산학부 교수(KAIST)
jongpark@kaist.ac.kr
(Corresponding author임)

논문접수 : 2025년 3월 26일
(Received 26 March 2025)
논문수정 : 2026년 6월 5일
(Revised 5 June 2026)
심사완료 : 2026년 6월 7일
(Accepted 7 June 2026)

Copyright©2026 한국정보과학회 : 개인 목적이나 교육 목적인 경우, 이 저작물의 전체 또는 일부에 대한 복사본 혹은 디지털 사본의 제작을 허가합니다. 이 때, 사본은 상업적 수단으로 사용할 수 없으며 첫 페이지에 본 문구와 출처를 반드시 명시해야 합니다. 이 외의 목적으로 복제, 배포, 출판, 전송 등 모든 유형의 사용행위를 하는 경우에 대하여는 사전에 허가를 얻고 비용을 지불해야 합니다.
정보과학회논문지 제53권 제9호(2026. 9)

1. 서 론

RAG(Retrieval-Augmented Generation)는 외부 지식 말뭉치 (Corpus)에서 관련 문서를 검색하여 대규모 언어 모델(Large Language Model; LLM)의 환각(Hallucination)을 줄이고 최신 정보에 기반한 신뢰성 있는 답변을 생성하도록 돕는 기술이다[1]. RAG 파이프라인은 검색기(Retriever)를 활용해 외부 문서를 검색하고 이 문서들을 바탕으로 LLM을 리더(Reader)로 활용해 답변을 생성하는 방식으로 작동한다. 하지만 RAG 과정에서 특정 성향을 가진 문서가 검색되거나[2], LLM이 학습 과정에서 발생한 편향성을 답변에 반영할 위험이 존재한다[3]. 이러한 문제는 기존의 편향성이 증폭되거나 새로운 편향성을 발생시켜, LLM이 생성하는 답변의 신뢰성과 공정성을 저해할 수 있다. 그러나 지금까지의 연구들은 주로 검색기나 LLM 자체에서 발생하는 편향 성에 개별적으로 집중되어 있고, 검색된 문서의 편향성과 RAG 과정에 미치는 영향에 대해서는 충분히 다루지 않았다.

본 연구는 "검색된 문서의 편향성이 답변 생성에 영향을 미칠까?"라는 연구 질문을 제기하며, 이를 검증하기 위해 두 가지 실험을 수행하였다. 먼저, 모델이 답변을 생성하는 과정에서 편향성이 있는 문서를 참조하여 답변을 생성하고, 생성된 답변의 편향성을 측정하여 참조한 문서의 편향성을 비교하였다. 이를 통해 참조된 문서의 편향성이 최종 답변에 일부 영향을 미칠 수 있음을 확인할 수 있었다. 그 다음, LLM을 활용해 문서의 편향적 요소를 완화한 후 수정한 문서를 참조하여 앞선 실험과 동일한 과정을 진행하였을 때, 생성된 답변의 편향성이 감소하는 것을 통해서도 검색된 문서 편향성이 실제로 존재한다는 것을 입증하였다. 우리는 이러한 현상을 "검색된 문서의 편향성이 모델이 생성한 답변에 전이되는 현상"으로 정의하고, RAG 과정에서 외부 지식 말뭉치에 포함된 편향성에 대한 주의가 필요함을 강조한다. 또한 모델에 내재된 편향성과 모델이 참조한 문서의 편향성 간의 우세성을 분석하기 위해서 두 편향성이 서로 충돌할 때 편향성 전이가 어떻게 달라지는지를 추가로 분석하였다. 그 결과, 우 편향 모델이 좌 편향 문서를 참조한 경우 좌 편향 응답으로의 변화를 보인 반면, 추가적인 우 편향 문서 참조가 응답에 미치는 변화는 미미한 것으로 나타났다.

본 논문의 기여점은 네 가지로 요약할 수 있다. 첫째, 기존 RAG 편향성 연구에서 다뤄온 검색기나 LLM의 편향성 외에도, 검색된 문서의 편향성에 대해 주목한다. 둘째, 검색된 문서의 편향성이 생성된 답변에 전이되는 문제를 실험적으로 확인하였다. 셋째, LLM을 활용해 이러한 문서 편향성을 중립적인 형태로 변환함으로써 생성된 답변의 편향성을 완화할 수 있음을 발견하였고, 이를 통해 검색 문서 편향의 존재에 대한 증거를 제시했다. 마지막으로, 모델 내부 편향성과 검색된 문서의 편향성의 충돌을 분석하였다. 실험에 사용된 모든 코드와 프롬프트는 공개되어 있다[1].

2. 관련 연구

최근 AI가 생성하는 편향된 콘텐츠가 사회에 미치는 부정적 영향에 대한 우려가 커지면서, 이를 탐지하고 완화하기 위한 연구가 활발히 진행되고 있다[4]. 특히, RAG의 적용 사례가 늘어나면서 발생하는 편향성 문제의 중요성도 더욱 부각되고 있다[5]. RAG는 검색기와 LLM으로 구성되어 있는데, 사전 학습 모델을 기반으로 한 검색기 역시 모델이 가지고 있는 편향성이 그대로 검색 결과에도 전이될 수 있다는 문제가 제기되었고[6], 이를 완화하기 위해 데이터 증강 기법이나, 학습 방법이 제안되었다[7]. 또한, LLM의 편향성을 탐지하고 개선하기 위한 여러 벤치마크와 평가 지표가 개발되었고[8] 이를 완화하기 위한 데이터 구성 방법들과 학습 방법들을 적용 중이나 여전히 한계가 존재한다[9]. 기존 연구들은 주로 검색기나 LLM 자체의 편향성에 집중했지만, RAG에서 참조되는 검색된 문서의 편향성이 최종 답변에 미치는 영향에 대한 연구는 부족하다. 본 연구는 이에 대응하여, RAG에서 검색된 문서 편향성이 LLM의 답변에 어떻게 반영되는지 탐구하여 해당 편향성의 존재를 밝히는 것을 목표로 한다.

3. 사전 연구: LLM의 편향성 평가 가능성 검증

본 연구의 실험에 앞서, LLM 기반 평가 방식이 편향성 평가에 활용 가능한지를 검증한다.

3.1 방법

최근 널리 사용되고 있는 LLM 기반 평가 방식이 문서의 편향 정도를 평가할 수 있는지 확인하였다. 이를 위해 특정 성향이 내재된 문서 T에 대하여 LLM을 활용하여 문서에 내재된 성향을 예측하도록 평가하였다. 문서에 대해 사전에 정리되어 있는 주석을 Bias(T), LLM을 활용하여 평가한 성향을 Eval(T)라고 정의하였다. 실험에 사용한 AllSides[2] 뉴스 데이터셋은 정치 전문가가 뉴스 기사 일부를 좌(Left), 우(Right), 중립(Center)으로 주석하여 제공되고 있다. 여기서 중립은

1) https://anonymous.4open.science/r/KSC2024_DocumentBias-BD5B

2) https://www.allsides.com

좌, 우 성향에서 나타나는 특징들을 띄지 않음을 의미하며, 본 연구는 중립이 좌, 우 성향보다 더 우월하다고 간주하지 않음을 명확히 한다. 본 실험에서는 주석된 정치 성향과 LLM을 통해 예측된 정치 성향을 비교하였다. 세 가지 성향에 대한 기사가 모두 존재하는 뉴스 주제 300개를 사용하였으며, 주제 별로 성향당 1개의 기사를 선정하여 총 900개의 기사 T_{Bias}를 사용하였다. 또한 T_{Bias}가 중복되지 않게 세 가지 성향에 대한 기사가 모두 존재하는 두 개의 주제를 선정하여 총 6개의 예시로 Few-shot 프롬프트를 구성하였다. 실험을 위한 평가 프롬프트는 기존 연구의 템플릿을 참고하여 작성하였으며[10], LLM으로는 OpenAI API를 활용하여 gpt-4o-2024-05-13[3]를 사용하였다. 모델 세부 매개변수는 Temperature=0.0, Top-p=1.0으로 설정하여 모델이 문서의 성향 평가에서 일관성을 보이도록 하였다. 마지막으로, 스피어만 상관 계수를 이용해 Bias(T)와 Eval(T) 간의 상관관계를 분석하였다. 스피어만 상관계수는 비모수적 방법으로, 단조 관계 평가에 적합하다.

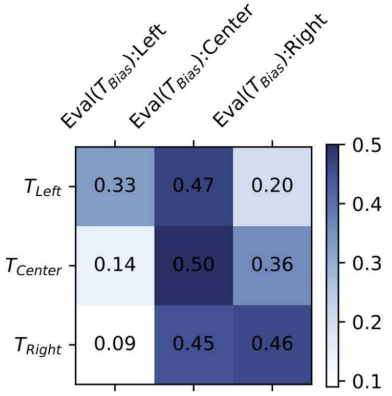


그림 1 AllSides에서 제공한 문서들의 전문가 주석 Bias(T_{Bias})에 대한 Eval(T_{Bias})의 비율을 나타낸 혼동 행렬 히트맵이다. 각 행은 전문가들이 평가한 문서의 성향을, 각 열은 LLM이 평가한 문서의 성향을 나타낸다

Fig. 1 This is a confusion matrix heatmap illustrating the proportion of Eval(T_{Bias}) corresponding to the expert-annotated Bias(T_{Bias}) of the documents provided by AllSides. Each row represents the document bias as evaluated by experts, and each column represents the document bias as evaluated by the LLM

3) https://platform.openai.com/docs/models/gpt-4o

3.2 결과 및 분석

그림 1은 LLM 기반 평가 방식이 성향 평가 방법으로 활용될 수 있음을 보여준다. Bias(T_{Bias})와 Eval(T_{Bias}) 간의 상관계수는 0.286로 중간 정도의 양의 상관관계를 나타내며, p-value는 0.0001 이하로 통계적으로 유의미하다. 이는 LLM의 정치적 성향을 평가하는 기준이 다각적임에도 불구하고, 전문가 주석과 높은 일치도를 보임을 의미한다. 이러한 결과는 LLM 기반 평가 방식이 뉴스 기사의 정치적 성향을 효과적으로 평가할 수 있다는 중요한 근거를 제공하며, 이에 따라 이후 실험에서는 LLM을 사용하여 정치적 편향성을 평가하였다.

4. 태스크 1: RAG에서 문서 편향성 전이 여부 확인

본 실험에서는 RAG에서 검색되어 LLM이 참조한 문서의 편향성이 생성된 답변에 전이되는지 여부를 확인하였다.

4.1 방법

LLM에 T_{Bias}를 in-context 형식으로 제공한 후, 모델이 T_{Bias}에 내재된 논쟁점을 설명하도록 프롬프트를 작성하여 LLM의 답변 Ans(T_{Bias})를 생성하였다. 검색기에서 발생할 수 있는 편향성 문제를 배제하기 위해, 검색 과정 이후의 상황을 가정하였으며, 3절에서 검증된 LLM 기반 평가 방식을 활용하여 Ans(T_{Bias})를 평가하였다. 이후, Bias(T_{Bias})와 Eval(Ans(T_{Bias})) 간의 상관관계를 분석하여 문서의 편향성이 답변에 전이되었는지를 확인하였다. 답변 생성 모델의 매개 변수를 Temperature=1.0으로 설정하였으며, 그 외 평가 모델을 비롯한 실험 세부사항들은 3절에서와 동일하게 유지하였다. 본 절에서는 3절에서 사용한 데이터와 중복되지 않는 900개의 뉴스 기사(T_{Bias})를 사용하였다. 실험 결과의 신뢰성을 높이기 위해 각 실험은 5회 반복하여 진행하였으며, 실험 결과는 각 Eval(Ans(T_{Bias}))들의 평균값으로 계산하였다.

4.2 결과 및 분석

그림 2의 태스크 1 결과는 LLM이 편향성을 띄고 있음과는 별개로 검색된 문서 편향성이 LLM이 생성한 답변에 전이된다는 것을 보여준다. LLM이 중립 성향의 문서를 참조하였을 때 중립된 답변을 90%로 가장 많이 생성하나 7.5%는 좌 성향, 3.5%는 우 성향으로 생성된다는 사실을 통해 LLM 자체로 인한 답변의 편향성이 있음을 확인할 수 있었다. 편향된 문서를 기반으로 답변을 생성한 경우 문서의 편향성이 생성된 답변에 명확히 전이되었다. 구체적으로, 좌 편향 문서를 참조하였을 경우 좌 성향의 답변이 8.9%로 증가하고 우

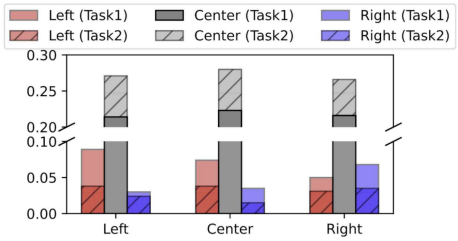


그림 2 AllSides에서 제공한 문서로부터 생성된 Ans(T_{Bias})와 Ans($T_{Neutral}$)가 각각 좌/중립/우 중 어느 성향으로 평가되었는지를 나타낸 막대그래프이다. 가로축의 세 막대 묶음은 원문 참조 문서 T_{Bias}의 성향을 의미한다. 세로축은 각 문서 그룹에서 생성된 답변이 특정 성향으로 평가된 비율을 나타낸다. 각 묶음 내 빨간색, 회색, 파란색 막대는 생성된 답변이 각각 Left, Center, Right로 평가되었음을 의미한다. 또한 빗금의 유무는 답변이 편향 문서 T_{Bias}를 기반으로 생성된 Ans(T_{Bias})인지, 편향 완화 문서 $T_{Neutral}$를 기반으로 생성된 Ans($T_{Neutral}$)인지 구분한다

Fig. 2 This bar chart presents the proportions of Ans(T_{Bias}) and Ans($T_{Neutral}$) evaluated as Left, Center, or Right based on the AllSides documents. The three bar groups on the x-axis represent the bias of the referenced documents T_{Bias}. The y-axis represents the proportion of generated answers assigned to each bias category. Within each group, the red, gray, and blue bars denote answers evaluated as Left, Center, and Right, respectively, while hatching distinguishes Ans(T_{Bias}) from Ans($T_{Neutral}$)

성향과 중립 성향의 답변의 수가 감소하였다. 반대로 우 편향 문서를 참조하였을 경우에도 우 성향의 답변이 6.8%로 증가하고 나머지 두 성향의 답변의 수는 감소하였다. 또한, Bias(T_{Bias})와 Ans(T_{Bias}) 간의 상관계수는 0.160으로 나타났으며, 이는 비교적 낮은 양의 상관관계를 의미한다. 그러나 p-value가 0.0001 이하로 통계적으로 유의미한 결과를 보였다. 이를 통해 검색된 문서의 편향성이 LLM이 생성하는 답변에 실질적으로 영향을 미친다는 사실을 확인할 수 있었다.

5. 태스크 2: RAG에서 편향성이 개선된 문서 활용 시 편향성 개선 여부 확인

본 실험에서는 중립적으로 변환된 문서를 기반으로 생성된 답변 내 편향성의 감소를 통해 문서 편향성의 존재를 확인하였다.

5.1 방법

문서 편향성이, 즉 좌, 우의 편향성이 드러나는 요소들을 제거하기 위해 LLM을 활용하였으며, 생성된 답변의 편향 정도를 측정하여 문서 편향성의 존재를 확인하였다. 먼저, 기존 문서 T_{Bias}를 중립적인 문서로 변환하였다. 이를 위해, Allsides에서 제공하는 좌/우 성향 기사들의 특징을 문맥에 제시한 뒤, 해당 성향이 완화되도록 성향별 특징을 완화하여 중립 성향의 문서 $T_{Neutral}$를 생성하라는 지시(Instruction)를 모델에 제공하였다. $T_{Neutral}$를 기반으로 Ans($T_{Neutral}$)를 생성하였고, Bias(T_{Bias})와 Eval(Ans($T_{Neutral}$)) 간의 상관관계를 계산하였다. 이를 통해 답변의 편향성이 완화되었는지 분석하여 문서 편향성의 존재를 확인하였다. 모든 실험은 4절에서 사용된 뉴스 기사(T_{Bias}) 900개를 동일하게 사용하며, 생성 및 평가 방법 또한 일관되게 적용하였다.

5.2 결과 및 분석

그림 2의 태스크 2 결과는 좌/우 성향을 완화하여 중립적으로 변환된 문서를 통해 생성되는 답변에서 검색된 문서의 편향성이 어떻게 영향을 끼치는지를 보여준다. 태스크 1과 비교했을 때, 태스크 2에서는 생성된 중립적인 성향의 답변이 총 65.2%에서 81.8%로 약 16%p 증가하였다. 좌편향의 경우 좌 성향의 답변이 5.2%p, 우편향의 경우 우 성향 답변이 3.3%p 감소하였다. 이는 좌/우 성향의 문서가 중립적으로 변환됨에 따라 중립 성향의 답변이 더 많이 생성되었음을 의미한다. 변환된 중립 문서를 사용한 경우 상관계수는 0.015로 크게 감소하였고, p-value는 0.632로 통계적으로 유의미하지 않아, Eval(Ans($T_{Neutral}$))과 Bias(T_{Bias}) 간의 관계가 거의 없음을 보여준다. 이는 LLM이 참조한 문서의 편향성을 완화하였을 때 생성되는 답변 역시 편향성이 완화되었음을 보여 검색 문서 편향성의 존재를 입증한 것이다. 이는 추후 RAG의 편향성 연구에서 문서의 편향성 또한 중요하게 고려해야 할 요소임을 강조한다.

5.3 사례 연구

표 1는 기존 문서 T_{Bias}와 중립적으로 변환된 문서 $T_{Neutral}$에 따라 각 문서에 기반하여 생성한 답변의 편향성이 어떻게 전이되는지 보여준다. 중립적으로 변환되면서 "abortion pills"가 "controversial healthcare topics pills"라는 용어로 변환되어, 편향성을 완화했다는 것을 볼 수 있다. 또한, Ans(T_{Bias})에서 "a strong stance against corporate interference in women's reproductive rights."라는 편향된 표현이 포함된 답변을 생성하는 것을 확인할 수 있으며, 이는 문서의 편향

표 1 태스크 1에서 편향적 문서 참조 시에 전이된 편향성과 태스크 2에서 편향 완화 문서 참조 시 완화된 편향성 사례 분석이다.

Table 1 Analysis of bias transferred from biased document references in Task 1 and cases of mitigated bias through referencing bias-mitigated documents in Task 2

Biased Document T_{Bias} (좌: Left) California Governor Gavin Newsom announced Monday that his state will no longer do business with Walgreens because the pharmacy chain decided not to dispense abortion pills. Walgreens initially said in January that it would offer mifepristone, one of the medications used to induce an abortion. The Food and Drug Administration changed its rules to allow pharmacies in states that still allow abortion to dispense the drug. Pharmacies would need to get certified to do so because the FDA currently classifies mifepristone as a high-risk drug, despite the fact that there...	**Bias-Mitigated Document $T_{Neutral}$** California Governor Gavin Newsom announced Monday that his state will no longer do business with Walgreens because the pharmacy chain decided not to dispense controversial healthcare topics pills. Walgreens initially said in January that it would offer mifepristone, one of the medications used to induce an abortion. The Food and Drug Administration changed its rules to allow pharmacies in states that still allow abortion to dispense the drug. Pharmacies would need to get certified to do so because the FDA currently classifies mifepristone as a high-risk drug, despite the fact that there...
Answer From Biased Document Ans(T_{Bias}) (좌: Left) The controversy in the given text surrounding Governor Gavin Newsom's decision to sever ties with Walgreens highlights a strong stance against corporate interference in women's reproductive rights. By refusing to dispense abortion pills, Walgreens is seen as capitulating to political pressure, which undermines access to essential healthcare for women, particularly in states that still protect abortion rights.	**Answer From Bias-Mitigated Document Ans($T_{Neutral}$) (중립: Center)** The controversy in the given text surrounding Governor Newsom's decision to stop doing business with Walgreens highlights the complex intersection of corporate decision-making and public health policies. While some support the pharmacy's cautious approach regarding a high-risk medication, others see it as limiting access to legal healthcare options. The controversy stems from balancing corporate autonomy with public access to medical services, without taking a clear side on the moral dimensions of the issue.

성이 해당 문서를 활용한 답변에 전이되는 것을 보여준다. Ans($T_{Neutral}$)의 경우 "the complex intersection of corporate decision-making and public health policies."와 같이 이전에 비해 편향성이 완화된 표현을 사용하였음을 확인할 수 있다. 또한 "While some support the pharmacy's cautious approach regarding a high-risk medication, others see it as limiting access to legal healthcare options."에서처럼 양측(좌/우)의 입장을 소개하는 방식으로 편향성을 완화하기도 하였다. 예시와 같이, 문서의 편향성이 완화되면 답변에서도 동일하게 편향성이 완화되는 것을 확인할 수 있다.

6. 추가 연구: LLM에 내재된 편향성과 검색된 문서의 편향성의 우세성 분석

정치 성향을 판단하는 질문들과 LLM을 활용하여 좌/우 성향의 문서를 각각 생성해 사용하였다. 이렇게 생성된 편향된 문서를 편향된 LLM이 참조할 때 최종적으로 생성된 답변은 어떠한 편향성을 가지는지를 바탕으로 LLM이 내재하고 있는 정치적 편향성과 참조한 문서의 정치적 편향성 중 어느 편향성이 우세한지를 확인하였다. 편향된 문서를 토대로 학습된 LLM을 활용하여 LLM에 내재된 정치적 편향성을 고정하였다. 다음은 앞서 설명한 실험에서 사용한 평가 방식, 좌/우 편향 문서 생성, 편향 모델에 대해 상세히 기술한다.

6.1 방법

편향된 문서를 토대로 학습된 LLM을 활용하여 LLM에 내재된 정치적 편향성을 고정하였고, 모델에 내재된 정치적 편향성과 일치하는 문서와 반대되는 문서를 각각 생성해 사용하였다. 이렇게 생성된 편향된 문서를 편향된 LLM이 참조할 때 최종적으로 생성된 답변은 어떠한 편향성을 가지는지를 바탕으로 LLM이 내재하고 있는 정치적 편향성과 참조한 문서의 정치적 편향성 중 어느 편향성이 우세한지를 확인하였다. 다음은 앞서 설명한 실험에서 사용한 평가 방식, 좌/우 편향 문서 생성, 편향 모델에 대해 상세히 기술한다.

평가 방식 [4]Political Compass Test는 정치적 성향을 설문 형식으로 평가하는 도구로 경제적, 사회적 이념에 대해 물어보는 62개의 질문으로 구성된다. 62개의 질문에 대한 답변을 종합하여 산출한 Political Compass 좌표평면 내 위치를 바탕으로 정치적 성향을 확인할 수 있다. Political Compass의 x축은 경제적 차원을 나타내며 좌측은 사회주의 관점을, 우측은 자본주의 관점을 의미한다. 한편, y축은 사회적 차원을 반영하여, 상단은 권위주의 성향, 하단은 자유주의 성향을 나타낸다. 각 질문은 "Strongly disagree", "Disagree", "Agree", "Strongly agree" 중 하나의 응답을 선택하도록 설계되어 있다. 본 실험에서는 각 질문과 함께 추가적인 문서를 제공하였을 때 한쪽 성향으로 편향된 LLM이 어떤 응답을 선택하는지를 종합하여, 최종 Political Compass 상의 어디에 위치하는지를 확인하였다.

좌/우 편향 문서 생성 좌 편향 문서와 우 편향 문서의 경우 Political Compass Test에서 사용되는 질문

4) https://www.politicalcompass.org/test/

과 함께 좌/우 성향의 특징을 LLM에 입력해 각각 생성하였다. 그리고 생성된 문서들이 실제로 의도에 맞게 편향되었는지 다른 종류의 LLM을 사용하여 확인하였다. 각 문서에 대한 성향 평가에는 LLM에 각 문서를 입력한 후 좌/중립/우 중 하나를 선택하라는 프롬프트를 사용하였으며, 총 62개의 질문에 대하여 좌/우 각각 5회 반복하였다. 편향된 문서 생성 시에는 OpenAI API 기반의 gpt-4o-2024-08-06[5] 모델을 활용하였고, 생성된 문서의 성향 평가에는 OpenAI API 기반의 o1-2024-12-17[6] 모델을 사용하였다. o1 모델은 추론 모델로, LLM 활용 평가 방법에서 다른 LLM에 비교해 우수한 성능을 보여 선택하였다[7]. 평가 결과, 좌 편향된 문서의 경우 100%, 우 편향된 문서의 경우 97.74%의 정확도를 나타내어 각 문서가 의도한 성향을 효과적으로 반영함을 확인하였다.

편향 모델 우선 LLM에 특정 정치적 성향(우 편향)을 내재시키기 위해 이전에 편향성이 확인된 정치적 성향을 가진 문서로 모델을 사전 구성[11][8] 하였다. 편향된 LLM은 외부 문서를 참조하지 않은 상태에서 자체적으로 특정 성향을 갖도록 설정하였다. 이렇게 구성된 편향 모델에 대해 세 가지 조건을 설정하였다. 1) 문서 미참조: 외부 문서 없이 편향 모델 자체의 성향만으로 답변 생성. 2) 좌 편향 문서 참조: 모델 내부 편향과 반대되는 성향의 문서(좌 편향)를 참조하여 답변을 생성. 3) 우 편향 문서 참조: 모델의 내재된 편향과 동일한 우 편향 문서를 참조하여 답변 생성 세 가지 조건 모두 동일한 평가 질문을 LLM에게 입력하여 각각의 답변을 생성하였다. 답변 생성 단계의 모델 세부 매개변수는 Temperature=0.0, Top-p=1.0으로 설정하여 결정론적인 답변을 유도하였다.

6.2 결과 및 분석

그림 3의 실험 결과에 따르면, 외부 문서 참조 없이 편향된 LLM의 내재적 지식만으로 생성된 답변(문서 미참조; 흰색 점)을 기준으로 비교했을 때, 좌 편향 문서 를 참조한 경우(빨간색 점) 모델의 최종 답변 성향은 내재된 우편향과 반대 방향인 좌측으로 크게 이동하였다. 구체적으로, 편향된 문서를 참조하지 않은 경우의 답변으로부터 좌 편향 문서를 참조한 경우까지의 Political Compass 상의 평균 이동 거리는 약 5.89로 나타났고, x좌표(경제적 성향)의 평균 변화는 약 -5.08

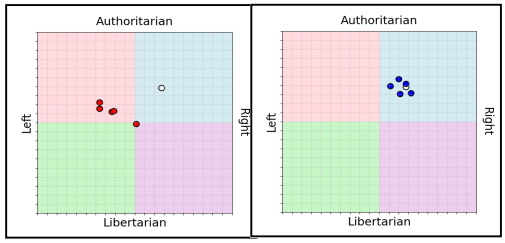


그림 3 우 편향된 LLM의 답변들을 종합해 Political Compass 상에 점으로 정치적 성향을 표시하였다. 왼쪽 그림은 문서 미참조 경우(흰색 점)와 좌 편향된 문서를 참조하였을 때 (빨간색 점)의 결과를, 오른쪽 그림은 문서 미참조 경우와 우 편향된 문서를 참조하였을 때(파란색 점)의 결과이다

Fig. 3 This figure visualizes the Political Compass distributions for a right-leaning LLM under three conditions: no external documents (white dots), left-leaning documents (red dots), and right-leaning documents (blue dots). The left figure shows the results for the no-document and left-leaning document conditions, whereas the right figure shows the results for the no-ocument and right-leaning document conditions

로, y좌표의 평균 변화는 약 -2.62로 좌측 방향으로 큰 폭의 이동을 보였다. 이는 참조된 문서에 존재하는 정치적 편향성이 우 편향을 내재한 LLM의 답변 성향을 실제로 반대 방향으로 강하게 유도할 수 있음을 시사한다. 반면, 우 편향 문서를 참조한 경우(파란색 점)는 참조하지 않은 경우와 비교할 때 성향이 거의 변하지 않았다. 편향된 문서를 참조하지 않은 답변과의 평균 거리는 약 0.99에 불과했고, 평균적인 x좌표 차이는 -0.50 정도, y좌표 차이는 -0.02로 변화 폭이 매우 작았다. 이는 LLM이 이미 우 편향을 가지고 있을 때, 같은 방향의 문서를 추가로 참조하더라도 답변의 편향성에 큰 변화가 없음을 보여준다.

이러한 결과를 종합하면, 편향된 LLM의 최종 답변은 참조하는 문서의 편향성이 내재된 편향성과 충돌할 때 크게 영향을 받지만, 내재된 편향성과 일치하는 문서를 참조할 경우에는 답변의 성향 변화가 미미하다. 다시 말해, 모델에 내재된 편향성과 참조 문서의 편향성이 충돌할 경우, 참조 문서의 영향력이 더욱 강력하게 나타날 수 있음을 의미한다. 다만, 이러한 편향성의 우세성 여부는 실험 설계, 내재된 편향성 정도 및 참조된 문서의 특징에 따라 달라질 가능성이 크다. 따라서 어느 한쪽의 우세성을 단정짓기보다는, RAG 시스템의

5) https://platform.openai.com/docs/models/gpt-4o
6) https://platform.openai.com/docs/models/o1
7) https://platform.openai.com/docs/guides/reasoning?api-mode=chat
8) https://huggingface.co/SaisExperiments/Evil-Alpaca-Right-Lean-L3.2-3B

편향성 문제를 분석할 때 LLM 자체의 편향성이나 검색 과정의 편향성만 개별적으로 분석하지 말고, 이들 편향 요소들이 서로 충돌하고 상호작용하는 맥락을 포괄적으로 이해하고 접근하는 것이 필요하다.

7. 결 론

본 연구는 RAG에서 검색된 문서의 편향성이 LLM이 생성하는 답변에 영향을 미치는 현상을 "검색된 문서의 편향성이 생성된 답변에 전이되는 문제"로 정의하고, 이를 실험적으로 입증하였다. 구체적으로 AllSides 뉴스 데이터셋을 활용하여, 참조 문서의 정치적 편향성이 생성된 답변에 실제로 전이됨을 확인하였고(태스크 1), 나아가 LLM을 활용해 편향된 문서를 중립적으로 변환했을 때 답변의 편향성 또한 효과적으로 완화됨을 보였다(태스크 2). 추가적으로 LLM 내부에 내재된 편향성과 참조 문서의 편향성이 서로 충돌할 경우, 참조 문서의 편향성이 모델 내재 편향성보다 답변에 우세한 영향을 미칠 수 있음을 확인하였으며, 여러 편향 요소들이 서로 충돌하고 상호작용하는 맥락을 포괄적으로 이해하고 접근하는 것의 필요성을 제시한다.

그러나 본 연구는 몇 가지 한계점 또한 지닌다. 우선, 정치 분야의 문서를 중심으로 연구가 수행되었기 때문에 그 결과를 다른 도메인으로 일반화하기에는 한계가 있다. 또한, 실험 과정에서 LLM 자체의 내재적 편향성으로 인해 평가 및 문서 생성 단계에서 의도하지 않은 추가적인 편향이 발생했을 가능성이 존재한다. 실험 설계 역시 우 편향 모델만을 대상으로 진행했기 때문에, 좌 편향 모델 또는 다양한 성향의 모델을 활용한 결과는 아직 충분히 검증하지 않았다. 더불어, 본 연구가 참조된 문서로부터 최종 답변으로부터의 편향 전이 현상에 초점을 맞추었기 때문에, LLM 내부에서 편향성이 형성되고 전이되는 구체적 메커니즘에 대한 심층적인 이해는 부족하다.

향후 연구에서는 경제, 사회, 문화 등 다양한 분야로 확장된 도메인을 대상으로 연구를 진행할 필요가 있으며, LLM 자체의 편향성을 보다 명확하게 제어하고 평가하는 실험 설계를 통해 편향 전이 현상에 대한 심층적 이해를 도모해야 한다. 이러한 접근은 RAG 시스템의 공정성과 신뢰성을 높이는 데 더욱 효과적으로 기여할 수 있을 것이다.

References

[1] P. Lewis et al., "Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks," *Advances in Neural Information Processing Systems,* Vol. 33, pp. 9459-9474, 2020.

[2] N. Rekabsaz and M. Schedl, "Do Neural Ranking Models Intensify Gender Bias?" *Proc. of the 43rd International ACM SIGIR Conference on Research and Development in Information Retrieval,* pp. 2065-2068, 2020.

[3] S. Gehman et al., "RealToxicityPrompts: Evaluating Neural Toxic Degeneration in Language Models," *Findings of the Association for Computational Linguistics: EMNLP 2020,* pp. 3356-3369, 2020.

[4] I. Garrido-Muñoz et al., "A Survey on Bias in Deep NLP," *Applied Sciences,* Vol. 11, No. 7, Article 3184, 2021.

[5] T.-E. Kim and F. Diaz, "Towards Fair RAG: On the Impact of Fair Ranking in Retrieval-Augmented Generation," *CoRR,* abs/2409.11598, 2024.

[6] S. Dai et al., "Bias and Unfairness in Information Retrieval Systems: New Challenges in the LLM Era," *Proc. of the 30th ACM SIGKDD Conference on Knowledge Discovery and Data Mining,* pp. 6437-6447, 2024.

[7] S. Dai et al., "Neural Retrievers are Biased Towards LLM-Generated Content," *Proc. of the 30th ACM SIGKDD Conference on Knowledge Discovery and Data Mining,* pp. 526-537, 2024.

[8] A. Parrish et al., "BBQ: A hand-built bias benchmark for question answering," *Findings of the Association for Computational Linguistics: ACL 2022,* pp. 2086-2105, 2022.

[9] OpenAI, "GPT-4 Technical Report," *CoRR,* abs/2303.08774, 2023.

[10] L. Zheng et al., "Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena," *Advances in Neural Information Processing Systems*, Vol. 36, pp. 46595-46623, 2023.

[11] A. Agiza et al., "PoliTune: Analyzing the Impact of Data Selection and Fine-Tuning on Economic and Political Biases in Large Language Models," *Proceedings of the AAAI/ACM Conference on AI,* Ethics, and Society, Vol. 7, No. 1, pp. 2-12, 2024.



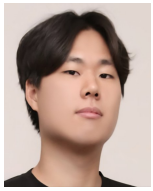
조 승 호

2023년~현재 KAIST전기및전자공학부 학사과정. 관심분야는 인공지능, 언어모델



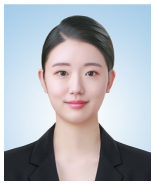
고 창 건

2024년 KAIST 전산학부 학사. 2026년 KAIST 전산학부 석사. 관심분야는 자연언어처리, 인공지능



황 태 호

2023년 경북대학교 컴퓨터학부 학사. 2025년 KAIST 전산학부 석사. 2025년 ~현재 삼성전자 엔지니어. 관심분야는 RAG, Agent



서 정 연

2022년 동국대학교 정치외교학과, 융합소프트웨어전공 학사. 2025년 KAIST 전산학부 석사. 2026년~현재 KAIST AI 미래학과 박사과정. 관심분야는 자연언어처리, 인공지능 윤리



박 종 철

1984년 서울대학교 컴퓨터공학 학사 1986년 서울대학교 컴퓨터공학 석사 1996년 미국 펜실베이니아 대학교 전산정보학 박사. 1998년~현재 KAIST 전산학부 교수. 관심분야는 계산언어학, 자연언어처리, 생물정보학, 삶의 질 개선 기술